**TÜRKİYE CUMHURİYETİ**
**YILDIZ TEKNİK ÜNİVERSİTESİ**
**BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ**

# DERİN SİNİR AĞLARI KULLANILARAK EL X-RAY GÖRÜNTÜLERİNDEN KEMİK YAŞI DEĞERLENDİRMESİ

21011605 — İSMAİL KÜÇÜKBAYRAK
21011703 — AYHAN ALİ ALTINSOY

**BILGISAYAR PROJESİ**

Danışman
Prof. Dr. Songül VARLI

Ocak, 2026

© Bu projenin bütün hakları Yıldız Teknik Üniversitesi Bilgisayar Mühendisliği Bölümü'ne aittir.

# TEŞEKKÜR

Bu çalışmanın gerçekleştirilmesi sürecinde bizlere yol gösteren, bilimsel bakış açısı kazandıran ve her aşamada desteğini esirgemeyen proje danışmanımız Prof. Dr. Songül VARLI'ya en içten teşekkürlerimizi sunarız. Kendisinin değerli katkıları, yapıcı yönlendirmeleri ve uzmanlığı, projenin hem akademik niteliğinin yükselmesine hem de araştırma sürecimizin doğru biçimde şekillenmesine büyük ölçüde katkı sağlamıştır.

Eğitim hayatımız boyunca bizlere gerekli altyapıyı sunan, teknik bilgi ve araştırma kültürü kazandıran Yıldız Teknik Üniversitesi Bilgisayar Mühendisliği Bölümü'ne teşekkür ederiz. Bölümümüzün sunduğu akademik ortam, laboratuvar imkânları ve eğitim anlayışı bu çalışmanın ortaya çıkmasında önemli bir rol oynamıştır.

Ayrıca proje sürecinde dolaylı ya da doğrudan katkı sağlayan tüm akademisyenlere, çalışma arkadaşlarımıza ve bizi destekleyen herkese teşekkürü bir borç biliriz. Bu çalışma, tüm bu katkıların birleşimiyle ortaya çıkmıştır.

İSMAİL KÜÇÜKBAYRAK
AYHAN ALİ ALTINSOY

# İÇİNDEKİLER

**KISALTMA LİSTESİ** **v**

**ŞEKİL LİSTESİ** **vi**

**TABLO LİSTESİ** **vii**

**ÖZET** **viii**

**ABSTRACT** **ix**

**1 GİRİŞ** **1**
1.1 Amaç . . . . . 2
1.2 Ön İnceleme . . . . . 2

**2 LİTERATÜR ANALİZİ** **3**

**3 SİSTEM ANALİZİ ve FİZİBİLİTE** **4**
3.1 Sistem Analizi . . . . . 4
3.2 Fizibilite . . . . . 4
3.2.1 Teknik Fizibilite . . . . . 4
3.2.2 Yasal Fizibilite . . . . . 5
3.2.3 Ekonomik Fizibilite . . . . . 5
3.2.4 İş Gücü ve Zaman Fizibilitesi . . . . . 5

**4 SİSTEM TASARIMI** **6**
4.1 Materyal ve Veri Kümesi . . . . . 6
4.2 Metot . . . . . 7

**5 DENEYSEL SONUÇLAR** **8**
5.1 Performans Analizi . . . . . 8
5.2 Karşılaştırmalı Analiz . . . . . 9

**6 SONUÇ VE TARTIŞMA** **11**

**Referanslar** **13**

**Özgeçmiş** **14**

# KISALTMA LİSTESİ

| | |
|---|---|
| CNN | Convolutional Neural Network |
| MAE | Mean Absolute Error |
| RMSE | Root Mean Square Error |
| $R^2$ | Coefficient of Determination |

# ŞEKİL LİSTESİ

Şekil 3.1 İş-Zaman Gantt Diyagramı . . . . . 5
Şekil 4.1 Articular Surface . . . . . 6
Şekil 4.2 Epiphysis . . . . . 6
Şekil 4.3 Model Mimarisi . . . . . 7
Şekil 5.1 Test Sonuç Grafiği . . . . . 8
Şekil 5.2 Veri Analizi . . . . . 9
Şekil 6.1 Örnek Sonuçlar . . . . . 11

# TABLO LİSTESİ

Tablo 5.1 Model Sonuçları . . . . . 9
Tablo 5.2 TEST SONUÇ TABLOSU . . . . . 10

# ÖZET

## DERİN SİNİR AĞLARI KULLANILARAK EL X-RAY GÖRÜNTÜLERİNDEN KEMİK YAŞI DEĞERLENDİRMESİ

İSMAİL KÜÇÜKBAYRAK
AYHAN ALİ ALTINSOY

Bilgisayar Mühendisliği Bölümü
Bilgisayar Projesi

Danışman: Prof. Dr. Songül VARLI

Bu çalışmada, el röntgeni görüntülerinden otomatik kemik yaşı tahmini gerçekleştirmek amacıyla derin öğrenme tabanlı bir yaklaşım önerilmiştir. Kemik yaşı değerlendirmesi, pediatrik radyolojide büyüme ve gelişimin izlenmesi açısından önemli bir tanı kriteridir ve manuel yöntemler hem zaman alıcı hem de gözlemciye bağlı hatalara açıktır. Bu nedenle çalışmada, süreci otomatikleştirebilecek bir CNN (Convolutional Neural Network) tabanlı model geliştirilmiştir.

Önerilen modelde, el röntgeni görüntülerinden önceden ayrıştırılmış articular surface ve epiphysis bölgeleri ayrı girişler olarak ele alınmıştır. Her iki görüntü kolu, transfer öğrenme yaklaşımıyla ImageNet üzerinde önceden eğitilmiş EfficientNet tabanlı derin ağlar kullanılarak işlenmiştir. Elde edilen yüksek seviyeli öznitelikler, cinsiyet bilgisi ile birlikte birleştirilmiş ve kemik yaşının regresyon problemi olarak tahmin edilmesi sağlanmıştır. Model eğitimi sırasında erken durdurma ve öğrenme oranı azaltma gibi yöntemlerle aşırı öğrenme riski kontrol altına alınmıştır.

Deneysel sonuçlar, test kümesi üzerinde elde edilen 10.42 ay MAE hata değerinin literatürle uyumlu ve gerçekçi olduğunu göstermektedir. Bu bulgular, geliştirilen yaklaşımın tıbbi görüntüleme alanında el röntgeni verileri üzerinden kemik yaşı tahmini için etkili ve güvenilir bir yöntem sunduğunu ortaya koymaktadır.

**Anahtar Kelimeler:** Kemik yaşı, derin öğrenme, tıbbi görüntüleme, el röntgeni, CNN

# ABSTRACT

## BONE AGE ASSESSMENT FROM HAND X-RAY IMAGES USING DEEP NEURAL NETWORKS

İSMAİL KÜÇÜKBAYRAK
AYHAN ALİ ALTINSOY

Department of Computer Engineering
Computer Project

Advisor: Prof. Dr. Songül VARLI

In this study, a deep learning–based approach is proposed for automatic bone age estimation from hand X-ray images. Bone age assessment is an important diagnostic task in pediatric radiology for monitoring growth and development; however, traditional manual methods are time-consuming and prone to inter-observer variability. To address these limitations, a CNN (Convolutional Neural Network)–based model is developed to perform bone age prediction automatically.

In the proposed framework, pre-segmented articular surface and epiphysis regions extracted from hand X-ray images are used as separate inputs to the model. Each image branch is processed using EfficientNet-based deep networks pretrained on ImageNet within a transfer learning paradigm. The high-level features extracted from both image branches are fused together with gender information and used to predict bone age as a regression task. During training, techniques such as early stopping and learning rate reduction are applied to mitigate overfitting.

Experimental results on the test dataset demonstrate that the proposed method achieves realistic and competitive 10.42 months MAE, consistent with findings reported in the literature. These results indicate that the developed model provides an effective and reliable solution for bone age estimation from hand X-ray images in the field of medical imaging.

**Keywords:** Bone age, deep learning, medical imaging, hand X-ray, CNN

# 1
# GİRİŞ

Pediatrik hastalarda kemik yaşının doğru ve hızlı belirlenmesi; büyüme ve gelişimin izlenmesi, endokrin bozuklukların değerlendirilmesi, tedavi süreçlerinin planlanması ve gerekli klinik müdahalelerin zamanında yapılabilmesi açısından kritik bir öneme sahiptir. Klinik uygulamalarda kemik yaşı çoğunlukla el-bilek bölgesine ait X-ray görüntülerinin uzman hekimler tarafından görsel olarak yorumlanmasıyla belirlenir. Ancak bu yöntem hem zamana duyarlıdır hem de değerlendirmeler arasında belirli düzeyde öznel farklılıklar görülebilir. Ayrıca yoğun klinik iş yükü altında standartlaştırılmış bir değerlendirmenin sürdürülmesi güçleşmektedir. Bu durum, hekimlerin karar verme süreçlerinde destekleyici teknolojilere olan ihtiyacı artırmakta ve sistematik bir yaklaşımın gerekliliğini ortaya koymaktadır.

Bu çalışma, derin öğrenme yöntemlerinden yararlanarak el X-ray görüntülerinden kemik yaşını otomatik olarak tahmin eden bir yaklaşımın geliştirilmesini konu almaktadır. Ayrıntıları ilgili bölümlerde açıklanmak üzere temel amaç; uzman yorumuna olan bağımlılığı azaltan, hızlı, tekrarlanabilir ve güvenilir sonuçlar üretmeye yönelik bir karar destek bileşeninin tasarlanmasıdır. Çalışmanın kapsamı, veri ön işleme adımlarından model mimarisinin oluşturulmasına, eğitim sürecinin yönetiminden performans değerlendirme aşamalarına kadar uzanan uçtan uca bir deneysel düzenek kurmayı içermektedir. Özgün katkı beklentisi ise, standartlaştırılmış bir veri işleme hattı ve şeffaf bir değerlendirme protokolü temelinde, klinik senaryolara uygulanabilir ve yeniden üretilebilir nitelikte bir yöntem ortaya koymaktır. Bu doğrultuda geliştirilen sistemin, mevcut literatüre hem teknik hem de uygulama odaklı bir katkı sağlaması hedeflenmektedir.

Bu bölümde, konunun taşıdığı önem ve projenin genel çerçevesi ele alınmıştır. Devam eden "Amaç" bölümünde çalışmanın hedefleri açık biçimde tanımlanacak; "Ön İnceleme" bölümünde mevcut yöntemlere ilişkin kısa bir değerlendirme sunulacak; ilerleyen bölümlerde ise literatür analizi, sistem tasarımı, model mimarisi ve fizibilite başlıkları ayrıntılı olarak incelenecektir. Böylece okuyucuya hem metodolojik altyapı hem de uygulama bağlamında kapsamlı bir görünüm sağlanması amaçlanmaktadır.

## 1.1 Amaç

Bu projenin amacı, el X-ray görüntülerinden kemik yaşını otomatik olarak tahmin edebilen derin öğrenme tabanlı bir sistem geliştirmektir. Bu sayede kemik yaşı değerlendirme sürecinde uzman yorumuna bağlı subjektiflik azaltılarak daha hızlı, standartlaştırılmış ve güvenilir sonuçların elde edilmesi hedeflenmektedir. Ayrıca geliştirilen modelin performansı klasik radyolojik yöntemlerle karşılaştırılarak yapay zekâ temelli yaklaşımların klinik kullanımdaki uygulanabilirliği de değerlendirilecektir.

## 1.2 Ön İnceleme

Kemik yaşı değerlendirmesi geleneksel olarak Greulich–Pyle ve Tanner–Whitehouse yöntemleri ile uzman hekimler tarafından el bileği X-ray görüntülerinin görsel olarak incelenmesine dayanır. Bu yöntemler yaygın olarak kullanılmakla birlikte yoruma açıktır, zaman alıcıdır ve değerlendiriciler arasında farklılıklar gösterebilir.

Son yıllarda derin öğrenme teknikleri, özellikle konvolüsyonel sinir ağları, tıbbi görüntü analizinde oldukça başarılı sonuçlar vermeye başlamıştır. Bu nedenle kemik yaşı tahmininde daha otomatik, hızlı ve tutarlı çıktılar sağlayabilen yapay zekâ tabanlı yaklaşımlar giderek daha fazla ilgi görmektedir. Bu proje, geleneksel yöntemlerin sınırlamalarını azaltmak ve modern makine öğrenimi/derin öğrenme yöntemlerinin bu alandaki uygulanabilirliğini incelemek amacıyla gerçekleştirilmiştir.

# 2
# LİTERATÜR ANALİZİ

Kemik yaşı tayini uzun yıllardır pediatrik görüntüleme alanında önemli bir araştırma konusudur. Geleneksel yaklaşımlar arasında Greulich-Pyle atlası [1] ve Tanner-Whitehouse yöntemi [2] yer almakta olup, bu yöntemler uzman radyologların el bileği radyografilerini görsel olarak incelemesine dayanır. Ancak bu değerlendirme süreci zaman alıcıdır ve yorumlayıcılar arasında farklılık gösterebilme riski taşımaktadır. Bu nedenle literatürde, değerlendirme sürecini hızlandırmak ve daha tutarlı sonuçlar elde etmek amacıyla bilgisayar destekli sistemlere yönelim artmıştır.

Derin öğrenme yöntemlerinin medikal görüntüleme alanında yaygınlaşmasıyla birlikte, kemik yaşı tahmini için Konvolüsyonel Sinir Ağları (CNN) temelli modeller geliştirilmiştir. Deng ve ekibinin sunduğu bir çalışmada, el X-ray görüntülerinden eklem yüzeyleri ve epifiz bölgelerine odaklanarak kemik yaşının tahmini gerçekleştirilmiştir [3]. Bu yaklaşım, tüm el görüntüsünü kullanan modellere kıyasla kemik gelişiminin kritik anatomik bölgelerini vurgulayarak doğruluğu artırmıştır. Liang ve arkadaşları ise tam otomatik bir CNN modeli geliştirerek veri ön işleme, özellik çıkarımı ve regresyon aşamalarını tek bir yapı içinde birleştirmiş, böylece geleneksel yöntemlere göre daha hızlı ve standardize edilmiş bir çözüm sunmuştur [4]. Guo ve arkadaşlarının önerdiği BoNet+ modeli ise özellikle düşük kalite veya bozulmuş görüntülerde daha kararlı tahminler yapabilmek amacıyla geliştirilmiştir [5].

Literatürde bu çalışmalar incelendiğinde, derin öğrenme modellerinin kemik yaşı tahmininde yüksek doğruluk ve tekrarlanabilirlik sunduğu görülmektedir. Bununla birlikte mevcut araştırmaların bazı sınırlılıkları bulunmaktadır. Özellikle veri dağılımı, farklı cihazlardan elde edilen görüntülerde kalite çeşitliliği ve dış validasyon eksiklikleri, modellerin klinik ortamlarda genellenebilirliğini kısıtlayabilmektedir. Bu proje, literatürde belirtilen bu eksiklikleri dikkate alarak veri ön işleme adımlarının standardize edilmesi, uygun doğrulama yöntemlerinin uygulanması ve yeniden üretilebilir bir model tasarımı ile mevcut çalışmalara katkı sağlamayı hedeflemektedir.

# 3
# SİSTEM ANALİZİ ve FİZİBİLİTE

## 3.1 Sistem Analizi

Sistem; görüntü yükleme, ön işleme, model eğitimi ve test aşamalarından oluşmaktadır. Kullanılan veri, kamuya açık tıbbi görüntü veri setlerinden temin edilmiş olup herhangi bir kişisel veri içermiyor.

Sistemin kullanıcı kitlesi, sağlık teknolojileri alanında çalışan araştırmacılar ve klinik karar destek sistemleri geliştiren yazılım ekipleridir. Proje araştırma odaklı olduğu için klinik ortamda doğrudan kullanım amaçlanmamaktadır; ancak geliştirilen yöntem, klinik sistemlere entegre edilebilecek temel bir yapay zeka bileşenidir.

Sistemin doğruluğunu ve başarımını değerlendirmek amacıyla Ortalama Mutlak Hata (MAE) metriği kullanılmıştır. Bu metrik, modelin tahmin doğruluğunun nicel olarak değerlendirilmesine imkan sağlamaktadır.

## 3.2 Fizibilite

### 3.2.1 Teknik Fizibilite

Proje Python programlama dili ile geliştirilmiş olup derin öğrenme için TensorFlow kullanılmıştır. Görüntü işleme aşamalarında OpenCV ve NumPy gibi kütüphanelerden yararlanılmıştır. Eğitim sürecinde GPU desteği gerekeceğinden Google Colab tercih edilmiştir. Bu araçlar açık kaynaklıdır ve proje için yeterli teknik kapasite sunmaktadır.

#### 3.2.1.1 Donanım Fizibilitesi

Model eğitimi ve test işlemleri için minimum 15GB RAM, GPU desteği ve 20GB depolama alanı yeterlidir. Bu gereksinimler ücretsiz bulut destekleri ile karşılanabildiğinden ek donanım yatırımı gerekmemiştir. Donanım altyapısı kısa ve orta vadede projeyi destekleyecek seviyededir.

### 3.2.2 Yasal Fizibilite

Proje kapsamında yalnızca kamuya açık veri setleri kullanılmıştırr. Gerçek hasta verisi işlenmemiş ve kişisel sağlık bilgisi barındırılmamıştır. Bu nedenle KVKK ve ilgili uluslararası veri koruma düzenlemelerine uyumludur. Patentli veya lisans gerektiren teknoloji kullanılmamaktadır.

### 3.2.3 Ekonomik Fizibilite

Kullanılan yazılımlar açık kaynaklıdır ve bulut tabanlı GPU kaynakları ücretsiz olarak temin edilebilmiştir. Bu nedenle proje geliştirme sürecinde maliyet oluşmamakta, ekonomik açıdan uygulanabilirlik sağlanmaktadır.

### 3.2.4 İş Gücü ve Zaman Fizibilitesi

Proje iki öğrenci ile bir danışman hoca tarafından yürütülmüştür. Süreç; literatür taraması, veri inceleme, model geliştirme, değerlendirme ve raporlama aşamalarından oluşmaktadır. Çalışma takvimi yaklaşık 10 haftadır. Aşamalar Şekil 3.1'deki Gantt diyagramı ile gösterilmiştir.

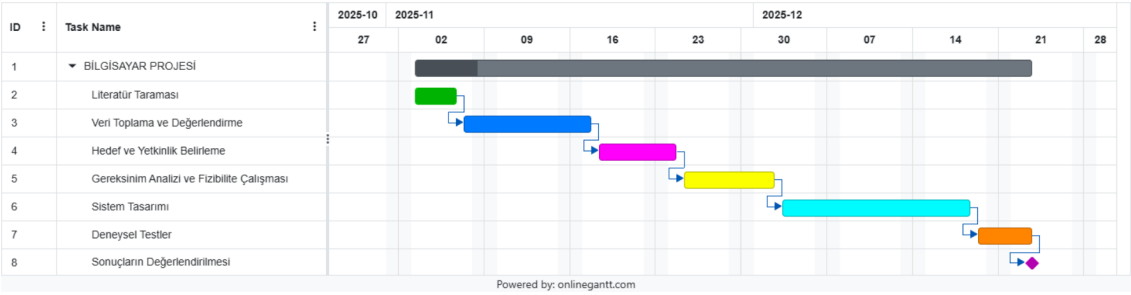


**Şekil 3.1** İş-Zaman Gantt Diyagramı

# 4
# SİSTEM TASARIMI

## 4.1 Materyal ve Veri Kümesi

Bu çalışmada kullanılan veri kümesi [6], el röntgeni (hand X-ray) görüntülerinden oluşmaktadır. Her birey için iki farklı anatomik bölgeyi temsil eden articular surface(Şekil 4.1) ve epiphysis(Şekil 4.2) görüntüleri kullanılmıştır. Görüntüler, ön işleme aşamasında ilgili anatomik bölgeler ayrıştırılarak arka plan etkisi minimize edilmiş ve modelin yalnızca kemik yapısına odaklanması sağlanmıştır.

Veri kümesinde her örnek için kemik yaşı etiketi ay cinsinden tanımlanmış olup, ayrıca bireyin cinsiyet bilgisi (erkek/kadın) yardımcı bir öznitelik olarak sunulmuştur. Tüm veriler, modelin genellenebilirliğini değerlendirmek amacıyla eğitim (train), doğrulama (validation) ve test kümeleri olacak şekilde ayrılmıştır. Bu ayrım, herhangi bir veri sızıntısını önlemek amacıyla her küme için ayrı görüntü dizinleri ve ayrı etiket dosyaları kullanılarak gerçekleştirilmiştir.

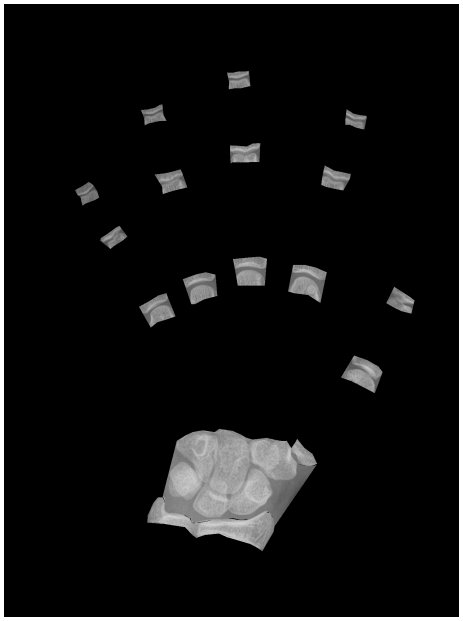

**Şekil 4.1** Articular Surface

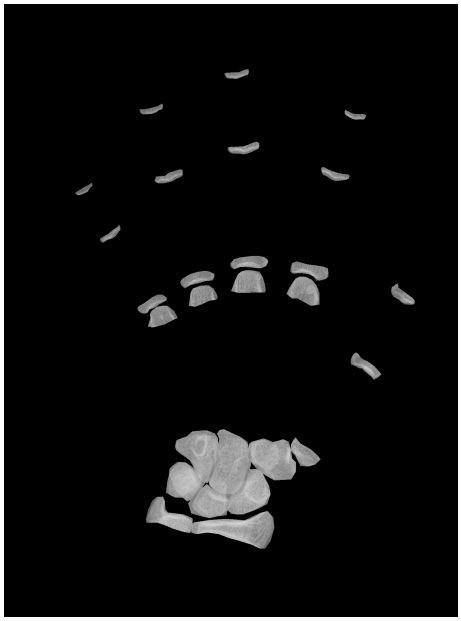

**Şekil 4.2** Epiphysis

## 4.2 Metot

Farklı model ailelerinden DenseNet121, ResNet50, EfficientNetB3 ve EfficientB0 modelleri denenmiş olup aralarından en iyi performansı gösteren EfficientNetB0 modeli seçilmiştir. Model mimarisi, iki ayrı görüntü girdisini işleyen çift dallı (dual-branch) CNN yapısına sahiptir. Articular surface ve epiphysis görüntüleri, birbirinden bağımsız iki EfficientNetB0 tabanlı derin ağ üzerinden işlenerek yüksek seviyeli öznitelikler elde edilmiştir.

Görüntüler modele girdi olarak verilmeden önce sabit bir boyuta (320×320 piksel) ölçeklendirilmiş ve derin öğrenme mimarisiyle uyumlu olacak şekilde ön işleme adımlarından geçirilmiştir. Bu yapı, hem hesaplama verimliliğini artırmış hem de transfer öğrenme kullanılan ağ mimarileriyle uyum sağlamıştır.

Her iki dalda da ImageNet üzerinde önceden eğitilmiş ağlar kullanılmış ve transfer öğrenme yaklaşımı benimsenmiştir. Eğitim sürecinde, ağın büyük bir kısmı dondurulmuş, yalnızca son katmanlar ince ayar (fine-tuning) amacıyla eğitime açılmıştır. Böylece, sınırlı veriyle daha kararlı ve etkili bir öğrenme süreci sağlanmıştır.

Elde edilen görüntü tabanlı öznitelikler, cinsiyet bilgisi ile birleştirilerek (feature-level fusion) tam bağlantılı katmanlara aktarılmıştır. Modelin çıkışında, normalize edilmiş kemik yaşı değerini tahmin eden tek nöronlu bir çıkış katmanı kullanılmıştır. Eğitim sırasında Ortalama Mutlak Hata (MAE) kayıp fonksiyonu tercih edilmiş; erken durdurma ve öğrenme oranı azaltma gibi düzenlileştirme yöntemleriyle aşırı öğrenme riski kontrol altına alınmıştır. Şekil 4.3'de model mimari özeti yer almaktadır.

Model: "functional"

| Layer (type) | Output Shape | Param # | Connected to |
|---|---|---|---|
| art_input (InputLayer) | (None, 320, 320, 3) | 0 | - |
| epi_input (InputLayer) | (None, 320, 320, 3) | 0 | - |
| EffNet_Art (Functional) | (None, 1280) | 4,049,571 | art_input[0][0] |
| EffNet_Epi (Functional) | (None, 1280) | 4,049,571 | epi_input[0][0] |
| male_input (InputLayer) | (None, 1) | 0 | - |
| fusion (Concatenate) | (None, 2561) | 0 | EffNet_Art[0][0], EffNet_Epi[0][0], male_input[0][0] |
| dense (Dense) | (None, 512) | 1,311,744 | fusion[0][0] |
| dropout (Dropout) | (None, 512) | 0 | dense[0][0] |
| dense_1 (Dense) | (None, 128) | 65,664 | dropout[0][0] |
| dropout_1 (Dropout) | (None, 128) | 0 | dense_1[0][0] |
| dense_2 (Dense) | (None, 1) | 129 | dropout_1[0][0] |

**Total params:** 9,476,679 (36.15 MB)
**Trainable params:** 3,620,705 (13.81 MB)
**Non-trainable params:** 5,855,974 (22.34 MB)

**Şekil 4.3** Model Mimarisi

Bu yöntemle el röntgeninden elde edilen farklı anatomik bilgiler birlikte değerlendirilmiş ve kemik yaşı tahmini problemine bütüncül bir yaklaşım sunulmuştur.

# 5
# DENEYSEL SONUÇLAR

## 5.1 Performans Analizi

Bu çalışmada geliştirilen derin öğrenme tabanlı modelin performansı, test kümesi üzerinde Ortalama Mutlak Hata (MAE),RMSE ve $R^2$ metrikleri kullanılarak değerlendirilmiştir. Model, test kümesinde yaklaşık 10.42 ay MAE değeri elde etmiştir. Bu sonuç, kemik yaşı tahmini probleminin doğası gereği zor ve yüksek varyansa sahip bir regresyon problemi olduğu göz önüne alındığında, gerçekçi ve kabul edilebilir bir performansa işaret etmektedir. Sonuç Şekil 5.1'deki grafikte gösterilmiştir.

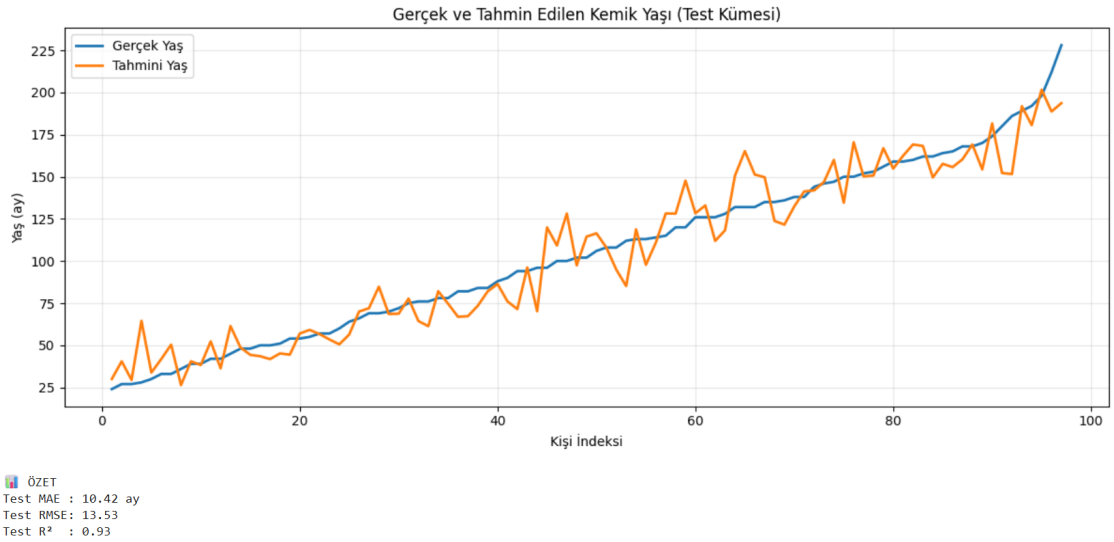


**Şekil 5.1** Test Sonuç Grafiği

Gerçek kemik yaşı ile model tarafından tahmin edilen kemik yaşı değerleri karşılaştırıldığında, genel eğilimin büyük ölçüde korunduğu ve tahminlerin özellikle orta yaş aralığında daha isabetli olduğu gözlemlenmiştir. Düşük ve yüksek yaş aralıklarında hata miktarının artması, literatürde de sıkça rapor edilen ve veri dengesizliği ile anatomik gelişim farklılıklarından kaynaklanan bir durumdur. Ayrıca bazı görüntülerin, görüntü kalitesinin çok düşük olmasının da test sonuçlarını olumsuz yönde etkilediği açıkça görünmektedir. Şekil 5.2'de görüntü kalitesi farklı bazı örnekler incelenebilir.

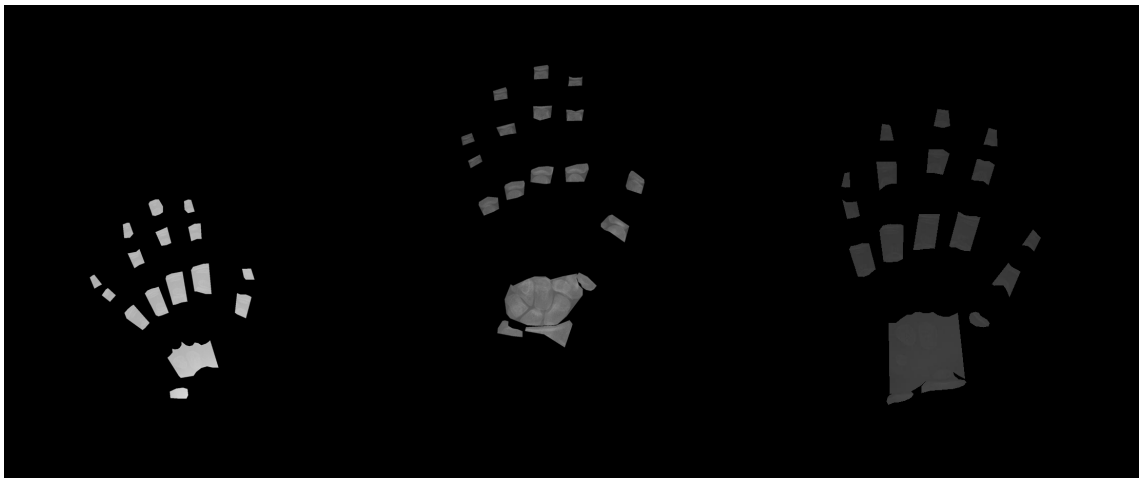

**Şekil 5.2** Veri Analizi

Modelin, articular surface ve epiphysis bölgelerinden elde edilen özellikleri birlikte kullanması, tek bir anatomik bölgeye dayalı yaklaşımlara kıyasla daha zengin bir temsil sunmuş ve tahmin performansını olumlu yönde etkilemiştir. Ayrıca cinsiyet bilgisinin yardımcı bir girdi olarak kullanılması, özellikle ergenlik öncesi ve sonrası dönemlerde kemik gelişimindeki farklılıkların daha iyi modellenmesine katkı sağlamıştır.

Elde edilen sonuçlar, geliştirilen modelin aşırı öğrenme göstermeden, eğitim ve doğrulama kümeleri arasında dengeli bir öğrenme süreci izlediğini ve test kümesi üzerinde farklı görüntü kalitesindeki verilere rağmen genellenebilir bir performans sergilediğini göstermektedir.

## 5.2 Karşılaştırmalı Analiz

Model seçiminde farklı model ailelerinden DenseNet121, ResNet50, EfficientNetB3 ve EfficientB0 modelleri denenmiş olup aralarından en iyi performansı gösteren EfficientNetB0 modeli seçilmiş ve bu model üzerinden projeye devam edilmiştir. Farklı modellerin test sonuçları; MAE,RMSE ve $R^2$ metrikleri kullanılarak karşılaştırılmış olup sonuçlar Tablo 5.1'de gösterilmiştir.

**Tablo 5.1** Model Sonuçları

| Model | MAE(month) | RMSE | $R^2$ |
|---|---|---|---|
| EfficientNetB0 | 10.42 | 13.53 | 0.93 |
| EfficientNetB3 | 11.55 | 14.70 | 0.91 |
| DenseNet121 | 13.31 | 18.40 | 0.86 |
| ResNet50 | 13.80 | 17.53 | 0.87 |

Önerilen yöntem, literatürde yer alan geleneksel kemik yaşı değerlendirme yöntemleri ve tek girişli derin öğrenme tabanlı yaklaşımlar ile kavramsal olarak karşılaştırılmıştır. Geleneksel Greulich–Pyle ve Tanner–Whitehouse gibi yöntemler, uzman değerlendirmesine dayalı olup subjektiflik ve gözlemciye bağlı farklılıklar içermektedir. Buna karşılık, bu çalışmada sunulan model tamamen otomatik olup, tutarlı ve tekrarlanabilir sonuçlar üretmektedir. Örnekler Tablo 5.2'de gösterilmiştir.

**Tablo 5.2** TEST SONUÇ TABLOSU

| 2*ID | Age (months) | | |
|---|---|---|---|
| | **Actual Age** | **Estimated Age** | **Difference** |
| 1433 | 24 | 30 | 6 |
| 1944 | 27 | 41 | 14 |
| 3040 | 27 | 30 | 3 |
| 3766 | 28 | 65 | 37 |
| 1407 | 30 | 34 | 4 |
| 1784 | 33 | 42 | 9 |
| 14235 | 33 | 50 | 17 |
| 1475 | 36 | 26 | 10 |
| 7484 | 39 | 41 | 2 |
| 8435 | 39 | 38 | 1 |
| 13954 | 42 | 52 | 10 |
| 14018 | 42 | 36 | 6 |
| 4332 | 45 | 61 | 16 |
| 12517 | 48 | 49 | 1 |
| 12936 | 48 | 44 | 4 |
| 3591 | 50 | 44 | 6 |
| 3616 | 50 | 42 | 8 |
| 9194 | 51 | 45 | 6 |
| 13518 | 54 | 45 | 9 |
| 13528 | 54 | 57 | 3 |
| 7625 | 55 | 59 | 4 |
| 4818 | 57 | 57 | 0 |

Literatürde rapor edilen CNN tabanlı kemik yaşı tahmin çalışmalarında test MAE değerlerinin genellikle 10–15 ay aralığında olduğu görülmektedir. Bu çalışmada elde edilen 10.42 ay test MAE değeri, söz konusu çalışmalarla uyumlu olup geliştirilen yaklaşımın rekabetçi bir performans sunduğunu göstermektedir. Özellikle iki farklı anatomik bölgenin (articular surface ve epiphysis) ayrı dallar üzerinden işlenmesi ve bu bilgilerin birleştirilmesi, tek görüntü girdisine dayalı modellere kıyasla önemli bir avantaj sağlamaktadır.

Sonuç olarak, önerilen çift girişli CNN mimarisi, hem literatürdeki benzer çalışmalarla karşılaştırıldığında rekabetçi sonuçlar üretmiş hem de kemik yaşı tahmini problemini daha bütüncül bir anatomik bakış açısıyla ele almıştır.

# 6
# SONUÇ VE TARTIŞMA

Bu çalışmada, el röntgeni görüntülerinden otomatik kemik yaşı tahmini amacıyla derin öğrenme tabanlı bir yöntem geliştirilmiştir. Önerilen yaklaşım, el röntgenlerinden elde edilen articular surface ve epiphysis bölgelerini ayrı girişler olarak ele alan çift dallı bir CNN mimarisine dayanmaktadır. Transfer öğrenme kullanılarak eğitilen model, görüntü tabanlı özniteliklerin yanı sıra cinsiyet bilgisini de yardımcı bir girdi olarak kullanarak kemik yaşı tahminini bir regresyon problemi olarak ele almıştır.

Deneysel sonuçlar, geliştirilen modelin test kümesi üzerinde 10.42 ay MAE değeri elde ettiğini ve bu performansın literatürde rapor edilen benzer çalışmalarla uyumlu olduğunu göstermiştir. Gerçek ve tahmin edilen kemik yaşı değerleri arasındaki ilişki incelendiğinde, modelin genel yaş dağılım eğilimini başarılı bir şekilde yakaladığı, ancak çok düşük ve çok yüksek yaş aralıklarında hata miktarının arttığı gözlemlenmiştir. Bu durum, veri dengesizliği ve kemik gelişiminin doğrusal olmayan yapısı ile açıklanabilir. Şekil 6.1'de üç farklı kişinin test sonucu verilmiştir.

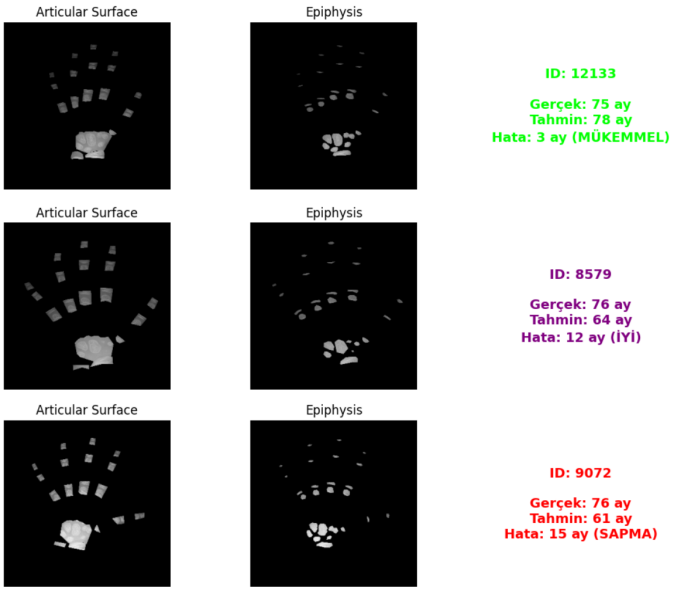


**Şekil 6.1** Örnek Sonuçlar

Çalışmanın önemli bir katkısı, tek bir anatomik bölgeye odaklanan yaklaşımlar yerine, kemik gelişimini farklı açılardan temsil eden iki ayrı bölgenin birlikte kullanılmasıdır. Bu sayede model, el röntgenindeki morfolojik bilgiyi daha kapsamlı bir şekilde değerlendirebilmiş ve tahmin performansını iyileştirmiştir. Ayrıca, cinsiyet bilgisinin modele entegre edilmesi, kemik gelişimindeki biyolojik farklılıkların daha doğru modellenmesine katkı sağlamıştır.

Bununla birlikte, çalışmanın bazı sınırlamaları da bulunmaktadır. Veri setindeki yaş dağılımının dengeli olmaması ve test örneği sayısının sınırlı olması, model performansını belirli yaş aralıklarında olumsuz etkilemiş olabilir. Gelecek çalışmalarda daha büyük ve dengeli veri setlerinin kullanılması, farklı omurga veya el kemiklerine ait ek anatomik bölgelerin modele dahil edilmesi ve gelişmiş kayıp fonksiyonlarının denenmesi ile performansın daha da artırılması mümkündür.

Sonuç olarak, bu çalışma kapsamında geliştirilen derin öğrenme tabanlı model, tıbbi görüntüleme alanında el röntgeni görüntülerinden kemik yaşı tahmini için etkili, güvenilir ve otomatik bir çözüm sunmaktadır. Elde edilen bulgular, yöntemin klinik karar destek sistemlerine entegre edilebilecek potansiyele sahip olduğunu göstermektedir.

# Referanslar


[1] EndoC Hesaplamalar. "Kemik yaşi atlasi (greulich & pyle)," Accessed: Jan. 22, 2026. [Online]. Available: https://www.endoc.com.tr/prg_web_kemik_yas_atlas/.

[2] J. M. Tanner and R. H. Whitehouse. "Tanner–whitehouse method (tw2/tw3)," Accessed: Jan. 22, 2026. [Online]. Available: https://radiopaedia.org/articles/tanner-whitehouse-method.

[3] Y. Deng et al., "Bone age assessment from articular surface and epiphysis using deep neural networks," *Mathematical Biosciences and Engineering*, vol. 20, no. 7, pp. 13 133–13 148, 2023. DOI: 10.3934/mbe.2023585. [Online]. Available: https://doi.org/10.3934/mbe.2023585.

[4] B. Liang et al., "A deep automated skeletal bone age assessment model via region-based convolutional neural network," *Future Generation Computer Systems*, vol. 98, pp. 54–59, 2019, ISSN: 0167-739X. DOI: https://doi.org/10.1016/j.future.2019.01.057. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0167739X18326153.

[5] J. Guo, J. Zhu, H. Du, and B. Qiu, "A bone age assessment system for real-world x-ray images based on convolutional neural networks," *Computers Electrical Engineering*, vol. 81, p. 106 529, 2020, ISSN: 0045-7906. DOI: https://doi.org/10.1016/j.compeleceng.2019.106529. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0045790618326569.

[6] YameiDeng, *Bone age assessment from articular surface and epiphysis using deep neural networks*, version 1.0, May 2023. DOI: 10.5281/zenodo.7947924. [Online]. Available: https://doi.org/10.5281/zenodo.7947924.

# Özgeçmiş

## BİRİNCİ ÜYE

**İsim-Soyisim:** İSMAİL KÜÇÜKBAYRAK
**Doğum Tarihi ve Yeri:** 25.09.2001, Şanlıurfa
**E-mail:** ismail.kucukbayrak@std.yildiz.edu.tr
**Telefon:** 0539 864 57 09
**Staj Tecrübeleri:**

## İKİNCİ ÜYE

**İsim-Soyisim:** AYHAN ALİ ALTINSOY
**Doğum Tarihi ve Yeri:** 16.09.1997, Aksaray
**E-mail:** ali.altinsoy@std.yildiz.edu.tr
**Telefon:** 0541 479 48 39
**Staj Tecrübeleri:**

## Proje Sistem Bilgileri

**Sistem ve Yazılım:** Windows, Python, Google Colab, CNN
**Gerekli RAM:** 15GB
**Gerekli Disk:** 20GB